Auteur 5.1 : **Dufour Emilien**

Groupe: Drapp Thibault, Badiane Issa, Dufour Emilien

5 janvier 2018

PLP rapport de TP Exercice 5

Question 5.1: TF-IDF par Emilien DUFOUR

Objectif:

Nous devons réaliser un programme Map-Reduce calculant le TF-IDF de chaque mot d'un ensemble de documents.

Méthode:

Soit TFIDF_{i,j}, le TFIDF du mot m_i du document d_j du corpus C.

 $TFIDF_{i,j} = wordcount(m_i,d_j) / card(d_j) * log10(card(C) / card(\{d \in C \ | \ m_i \in d\}))$

On effectue une série de 3 Map-Reduce sur notre Corpus.

	Key	Value			
Map 1	[mot i, doc j]	1			
Shuffle 1	[mot i, doc j]	{1,1,,1}			
Reduce 1	[mot i, doc j]	Wordcount _{i,j}			
Map 2	doc j	$[mot\ i, wordcount_{i,j}]$			
Shuffle 2	doc j	$\{[\text{mot } 1, \text{wordcount}_{l,j}],, [\text{mot } N, \text{wordcount}_{N,j}]\}$			
Reduce 2	[mot i, doc j]	$[Wordcount_{i,j}\ , lengthdoc_j]$			
Map 3	mot i	$[docj,wordcount_{i,j},lengthdoc_j]$			
Shuffle 3	mot i	$ \begin{aligned} \{[\text{doc 1, wordcount}_{i,1}, \text{lengthdoc}_1],, [\text{doc } M, \\ & \text{wordcount}_{i,M}, \text{lengthdoc}_M] \} \end{aligned} $			
Reduce 3	[mot i, doc j]	$[Wordcount_{i,j} \ , lengthdoc_{j} \ , nbrDocHavingMot_{i}]$			
	>	[TF-IDF i,j]			

Résumé et remarques importantes :

On applique donc en cascade 3 fois l'architecture java pour les jobs MapReduce.

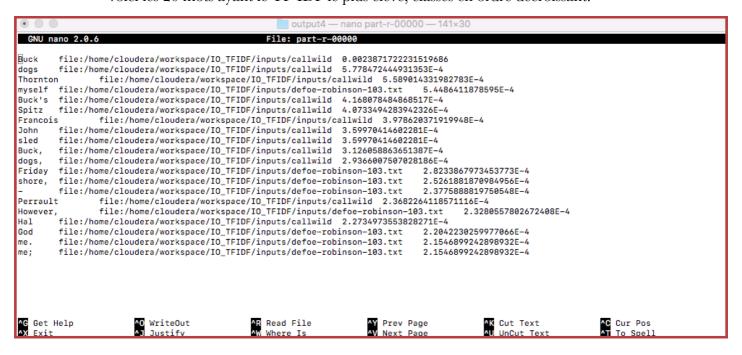
La complexité réside dans la gestion des clefs composites et dans l'implémentation de plusieurs boucles sur les mêmes « values » dans le Reducer.

- Pour les clefs composites, on crée donc des classes dont les attributs sont les éléments de nos vecteurs clefs. Ces classes implémentent l'interface
 « WritableComparale < Composite Key > ».
- Pour les boucles dans le Reducer : il s'agit de générer à l'issue du Reducer plus de clefs que celles reçues. C'est le cas par exemple du Reducer du round2 : on émet des couples clef : <mot i, doc j> valeur : <mot i, tailleDoc j> alors que le Mapper émettait clef : <doc j> valeur : <mot i, wordcount ij> (voir schéma ci-dessus).

Il faut donc que le Reducer fasse deux boucles sur le même objet « Iterator ». Pour cela on crée un cache qui contiendra les « values » et que l'on remplit dans la première boucle. Il faudra faire attention à remplir le cache en créant des copies des objets contenus dans «Iterator», afin de ne pas faire pointer les objets de notre cache vers le même objet.

Résultats:

Voici les 20 mots ayant le TF-IDF le plus élevé, classés en ordre décroissant.



On a d'abord calculé le wordcount de toutes les paires (**mot i , doc j**).

```
output1 - nano part-r-00000 - 142×35
    GNU nano 2.0.6
                                                                                                                                                                                                                                                                                    File: part-r-00000
                                               file:/home/cloudera/workspace/IO TFIDF/inputs/callwild
'we've file:/home/cloudera/workspace/IO_TFIDF/inputs/callwild 1
'whoa! file:/home/cloudera/workspace/IO_TFIDF/inputs/callwild 1
'why file:/home/cloudera/workspace/IO_TFIDF/inputs/callwild 1
('gas' file:/home/cloudera/workspace/IO_TFIDF/inputs/callwild 1
(I file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt 4
(Points file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt 1
(September, file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt
                                          ber, file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt
file:/home/cloudera/workspace/IO_TFIDF/inputs/callwild 1
file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt 9
file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt 1
file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt 1
file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt 1
file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt 1
file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt 1
file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt
 (as
 (cakes
(first)
  (for
   (for
  (for,
                                         y file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-file:/home/cloudera/workspace/IO_TFIDF/inputs/callwild 1 file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt file:/home/cloudera/workspace/IO_TFIDF/inputs/callwild 2 file:/home/cloudera/workspace/IO_TFIDF/inputs/callwild 1 file:/home/cloudera/workspace/IO_TFIDF/inputs/callwild 2 file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt file:/home/cloudera/workspace/IO_TFIDF/inputs/callwild 1 file:/home/cloudera/workspace/IO_TFIDF/inputs/defoe-robinson-103.txt
  (happily
  (ifI
 (it
  (of
  (or
  (seventy
  (still
                                                                                                                                                                                                                                                               ^R Read File
^W Where Is
                                                                                                                                                                                                                                                                                Read File
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                ^K Cut Text
^U UnCut Text
^G Get Help
^X Exit
                                                                                                                               ^O WriteOut
^J Justify
                                                                                                                                                                                                                                                                                                                                                                                                ^Y Prev Page
^V Next Page
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              To Spell
```

Ensuite on calcule le nombre de mots par document et on l'associe aux couples (mot i , doc j , wordcount ij).

• •		output2 —	- nano par	t-r-00	0000 — 142:	×35						
GNU nano	GNU nano 2.0.6 File: part-r-00000											
	le:/home/cloudera/workspace/IO_TFIC			31778								
cheerful.	file:/home/cloudera/workspace			1	31778							
	le:/home/cloudera/workspace/IO_TFID			31778								
	le:/home/cloudera/workspace/IO_TFID			31778								
ranging;	file:/home/cloudera/workspace			1	31778							
	le:/home/cloudera/workspace/IO_TFID		1	31778								
	le:/home/cloudera/workspace/IO_TFID		1	31778								
	le:/home/cloudera/workspace/IO_TFID		1	31778								
	le:/home/cloudera/workspace/IO_TFID		1	31778								
	le:/home/cloudera/workspace/IO_TFID		1	31778								
	le:/home/cloudera/workspace/IO_TFIC		5	31778								
	le:/home/cloudera/workspace/IO_TFIC		1	31778								
	le:/home/cloudera/workspace/IO_TFIC		1	31778								
	le:/home/cloudera/workspace/IO_TFID		1	31778								
	le:/home/cloudera/workspace/IO_TFIC		4	31778								
	le:/home/cloudera/workspace/IO_TFID		17	31778								
instructin						1	121547					
	le:/home/cloudera/workspace/IO_TFIC					121547						
	le:/home/cloudera/workspace/IO_TFIC					121547						
	le:/home/cloudera/workspace/IO_TFIC					121547						
	le:/home/cloudera/workspace/IO_TFID				1	121547						
yourself	file:/home/cloudera/workspace					1	121547					
	le:/home/cloudera/workspace/IO_TFIC					121547						
	le:/home/cloudera/workspace/IO_TFIC					121547						
	le:/home/cloudera/workspace/IO_TFIC					121547						
	le:/home/cloudera/workspace/IO_TFIC					121547						
	le:/home/cloudera/workspace/IO_TFIC					121547						
	le:/home/cloudera/workspace/IO_TFIC				34	121547						
	le:/home/cloudera/workspace/IO_TFIC				5	121547						
you;" fi	le:/home/cloudera/workspace/IO_TFIC	H/inputs/defoe-rob	inson-10	s.txt	1	121547						
^G Get Hel	p 40 WriteOut	AR Read File	AV	Prev	Page	٨K	Cut Text	^C Cur Pos				
^X Exit	AJ Justify	AW Where Is	۸V	Next	_	ΛU	UnCut Text	^T To Spell				
A CAIC	o datily		_		· ogo	U	5.100 E . 10X E	.5 50011				

Ensuite on calcule le nombre de documents contenant un certain mot. En associant ces quantités aux couples (mot i, doc j, wordcount ij, tailleDoc j), on détermine les couples (mot i, doc j, TFIDF ij).



Enfin on sélectionne les 20 couples (**mot i , doc j , TFIDF ij**) ayant les plus forts TFIDF.